Teoría Econométrica II

Estimación e inferencia en diferencias en diferencias

João Garcia

Universidad de Santiago de Chile

Clase 10 — 26 de octubre de 2026

Dónde quedamos

El miércoles: el 2×2. Tendencias paralelas identifica el ATT; las tendencias previas son la implicancia testeable, pero un test que no rechaza dice poco.

Dónde quedamos

El miércoles: el 2×2. Tendencias paralelas identifica el ATT; las tendencias previas son la implicancia testeable, pero un test que no rechaza dice poco.

Hoy, tres preguntas:

1. Con muchos períodos, ¿qué se estima y cómo se hace inferencia?
2. ¿Cuánto creerle a las pre-tendencias? Potencia del test y una alternativa: **cuánta** violación cambiaría la conclusión.
3. ¿Y si las tendencias son paralelas solo **entre unidades parecidas**? Tendencias paralelas condicionales.

Todavía con **una sola fecha** de tratamiento. Fechas distintas: miércoles.

1

Estimación e inferencia

Del 2×2 al estudio de eventos

Tratados desde t^*, controles nunca. Un coeficiente por año relativo $k = t - t^*$, con $k = -1$ como referencia:

$$Y_{it} = \alpha_i + \lambda_t + \sum_{k \neq -1} \beta_k \, D_i \, \mathbf{1}\{t - t^* = k\} + \varepsilon_{it}.$$

Del 2×2 al estudio de eventos

Tratados desde t^*, controles nunca. Un coeficiente por año relativo $k = t - t^*$, con $k = -1$ como referencia:

$$Y_{it} = \alpha_i + \lambda_t + \sum_{k \neq -1} \beta_k D_i \mathbf{1}\{t - t^* = k\} + \varepsilon_{it}.$$

Resultado — Cada β_k es un 2×2 contra $t^* - 1$ (pizarra 1)

$\hat{\beta}_k$ = (cambio de los tratados entre $t^* - 1$ y $t^* + k$) − (cambio de los controles). Con tendencias paralelas y sin anticipación: $\beta_k = \text{ATT}_k$ si $k \geq 0$, y $\beta_k = 0$ si $k < -1$.

Del 2×2 al estudio de eventos

Tratados desde t^*, controles nunca. Un coeficiente por año relativo $k = t - t^*$, con $k = -1$ como referencia:

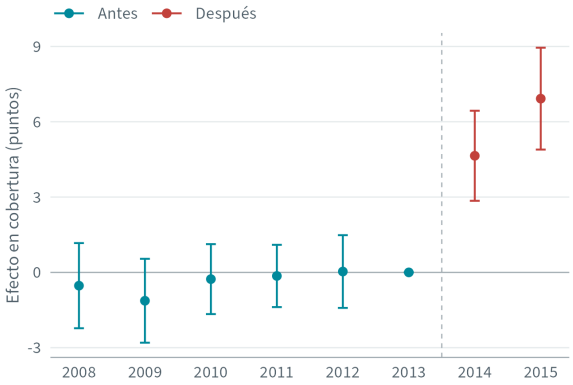
$$Y_{it} = \alpha_i + \lambda_t + \sum_{k \neq -1} \beta_k D_i \mathbf{1}\{t - t^* = k\} + \varepsilon_{it}.$$

Resultado — Cada β_k es un 2×2 contra $t^* - 1$ (pizarra 1)

$\hat{\beta}_k$ = (cambio de los tratados entre $t^* - 1$ y $t^* + k$) − (cambio de los controles). Con tendencias paralelas y sin anticipación: $\beta_k = \text{ATT}_k$ si $k \geq 0$, y $\beta_k = 0$ si $k < -1$.

- Sin tendencias paralelas, $\beta_k = \text{ATT}_k + \delta_k$, con δ_k la diferencia de tendencias entre $t^* - 1$ y $t^* + k$.
- Todos comparten el año $t^* - 1$: están **correlacionados** entre sí.

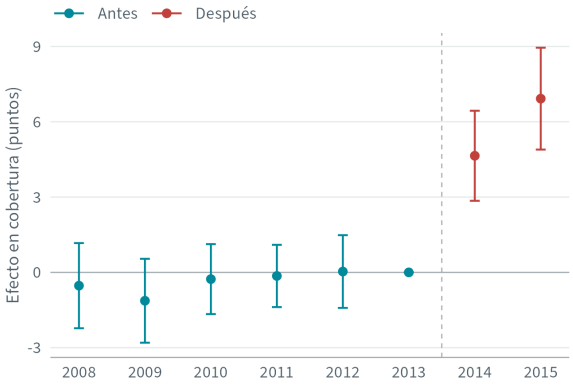
La expansión de Medicaid (2014)



Ley de Cuidado de Salud (ACA): 22 estados amplían Medicaid en 2014; 21 no (o lo hacen después de 2015). Tasa de cobertura de adultos de bajos ingresos sin hijos (Rambachan y Roth, 2023).

- 2014: 4,6 puntos (e.e. 0,9); 2015: 6,9.
- El coeficiente de 2014 es **exactamente** el 2×2 con 2013 y 2014.
- Pre-tendencias: test conjunto de los 5 coeficientes previos, valor $p = 0{,}53$.

La expansión de Medicaid (2014)



Ley de Cuidado de Salud (ACA): 22 estados amplían Medicaid en 2014; 21 no (o lo hacen después de 2015). Tasa de cobertura de adultos de bajos ingresos sin hijos (Rambachan y Roth, 2023).

- 2014: 4,6 puntos (e.e. 0,9); 2015: 6,9.
- El coeficiente de 2014 es **exactamente** el 2×2 con 2013 y 2014.
- Pre-tendencias: test conjunto de los 5 coeficientes previos, valor $p = 0{,}53$.

¿Listo? “No rechazo” ya sabemos que no basta.

Inferencia: qué cuenta

- **Agrupar al nivel de la asignación** (el estado). Con muchos años, la correlación serial dentro del estado se come los errores estándar (Bertrand, Duflo y Mullainathan; clase 7).
- Cuentan los ***clusters* tratados**. Medicaid: 22 y 21, bien. Con 2 o 3: CR2 y Bell–McCaffrey. Con uno: nada funciona; control sintético (4 de noviembre).
- Leer el gráfico completo ("¿todos los previos tocan el cero?") pide bandas **simultáneas** (sup-t), más anchas que las puntuales.

Inferencia: qué cuenta

- **Agrupar al nivel de la asignación** (el estado). Con muchos años, la correlación serial dentro del estado se come los errores estándar (Bertrand, Duflo y Mullainathan; clase 7).
- Cuentan los ***clusters* tratados**. Medicaid: 22 y 21, bien. Con 2 o 3: CR2 y Bell–McCaffrey. Con uno: nada funciona; control sintético (4 de noviembre).
- Leer el gráfico completo (“¿todos los previos tocan el cero?”) pide bandas **simultáneas** (sup-t), más anchas que las puntuales.

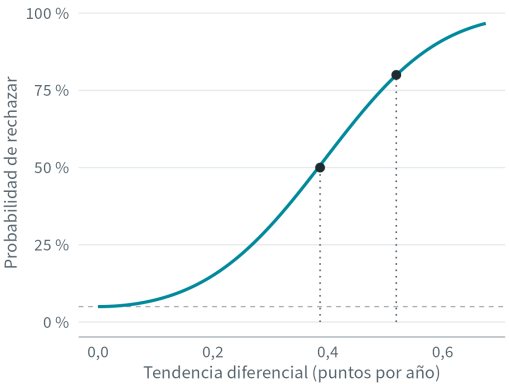
⚠ Qué puede fallar

El error estándar mide el ruido de **muestreo**. No mide la incertidumbre sobre tendencias paralelas, que suele ser mayor: el resto de la clase.

2

¿Cuánto creerle a las pre-tendencias?

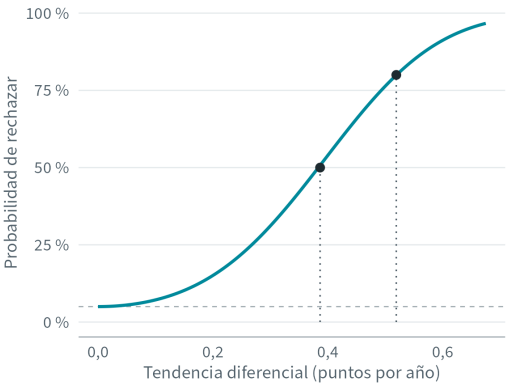
Potencia: ¿qué tendencia detectaría el test?



Roth (2022): supongamos que **sí** hay una violación, una tendencia lineal $\delta_k = \gamma\,(k+1)$. ¿Con qué probabilidad la detecta el test?

- Con la varianza de Medicaid, el test rechaza la mitad de las veces si γ = 0,39 puntos por año, y el 80 % si γ = 0,52 (pizarra 2).
- Esa tendencia de 50 % sesga el efecto de 2014 en 0,39 puntos y el de 2015 en 0,77.

Potencia: ¿qué tendencia detectaría el test?



Roth (2022): supongamos que **sí** hay una violación, una tendencia lineal $\delta_k = \gamma\,(k+1)$. ¿Con qué probabilidad la detecta el test?

- Con la varianza de Medicaid, el test rechaza la mitad de las veces si γ = 0,39 puntos por año, y el 80 % si γ = 0,52 (pizarra 2).
- Esa tendencia de 50 % sesga el efecto de 2014 en 0,39 puntos y el de 2015 en 0,77.

Aquí el efecto es 4,6 puntos: el test tiene potencia contra violaciones que importarían. En artículos publicados, Roth encuentra muchos casos donde **no**.

Pasar el test también sesga

Simulación con la varianza de Medicaid: efecto **cero** y la tendencia que el test detecta la mitad de las veces.

- Sin filtrar, el coeficiente de 2014 promedia el sesgo de la tendencia: 0,39 puntos.
- Entre los que **pasan** el test (49 %): 0,66 puntos. El sesgo crece 71 %.

Pasar el test también sesga

Simulación con la varianza de Medicaid: efecto **cero** y la tendencia que el test detecta la mitad de las veces.

- Sin filtrar, el coeficiente de 2014 promedia el sesgo de la tendencia: 0,39 puntos.
- Entre los que **pasan** el test (49 %): 0,66 puntos. El sesgo crece 71 %.

Por qué (pizarra 2): los $\hat{\beta}_k$ previos y posteriores comparten $\bar{Y}_{t^*-1}$. Pasar el test exige que el ruido empuje los previos hacia el cero, contra la tendencia; ese mismo ruido en $t^* - 1$ empuja los posteriores en la dirección del sesgo.

Pasar el test también sesga

Simulación con la varianza de Medicaid: efecto **cero** y la tendencia que el test detecta la mitad de las veces.

- Sin filtrar, el coeficiente de 2014 promedia el sesgo de la tendencia: 0,39 puntos.
- Entre los que **pasan** el test (49 %): 0,66 puntos. El sesgo crece 71 %.

Por qué (pizarra 2): los $\hat{\beta}_k$ previos y posteriores comparten $\bar{Y}_{t^*-1}$. Pasar el test exige que el ruido empuje los previos hacia el cero, contra la tendencia; ese mismo ruido en $t^* - 1$ empuja los posteriores en la dirección del sesgo.

Intuición

El test no es inútil: es mejor que no mirar. Pero usarlo como filtro (“pasó, entonces reporto el DiD”) no corrige el sesgo, y lo esconde.

Sensibilidad: Rambachan y Roth (2023)

En vez de testear $\delta_{\text{pre}} = 0$, suponer algo **más débil** sobre δ_{post}, disciplinado por lo que se ve en el período previo.

Definición — Dos restricciones sobre la violación

Magnitudes relativas, $\bar{M}$: el salto de un año a otro en la violación después de t^* no supera $\bar{M}$ veces el mayor salto observado antes.
Suavidad, M: la pendiente de la violación cambia a lo más M por año. $M = 0$ es "la tendencia previa sigue en línea recta".

Sensibilidad: Rambachan y Roth (2023)

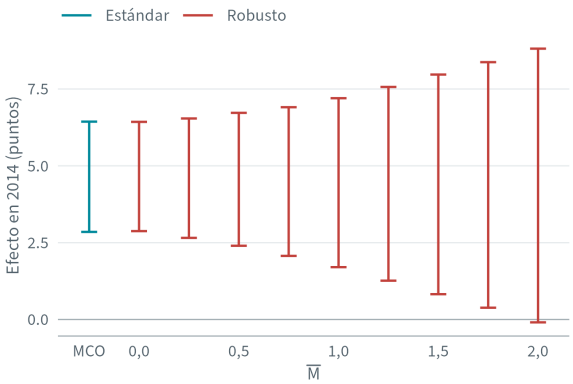
En vez de testear $\delta_{\text{pre}} = 0$, suponer algo **más débil** sobre δ_{post}, disciplinado por lo que se ve en el período previo.

Definición — Dos restricciones sobre la violación

Magnitudes relativas, $\bar{M}$: el salto de un año a otro en la violación después de t^* no supera $\bar{M}$ veces el mayor salto observado antes.
Suavidad, M: la pendiente de la violación cambia a lo más M por año. $M = 0$ es "la tendencia previa sigue en línea recta".

- Para cada $\bar{M}$ (o M) el efecto queda **identificado parcialmente**: un intervalo de valores compatibles. El intervalo robusto le suma el ruido de muestreo.
- $\bar{M} = 0$ es tendencias paralelas. El reporte natural: el **punto de quiebre**, el menor $\bar{M}$ con el que el intervalo incluye el cero.

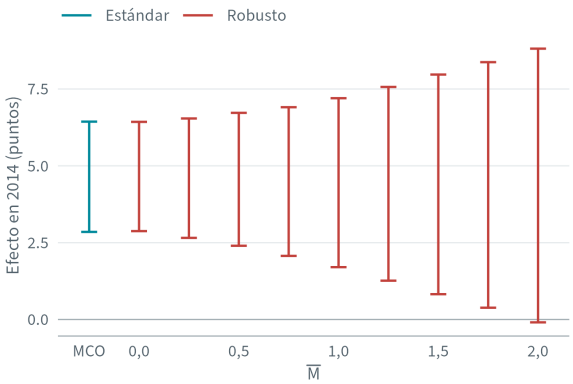
Medicaid: intervalos robustos



Efecto en 2014; intervalos de 95 % con `HonestDiD`.

- Mayor salto previo: 0,86 puntos.
- Excluye el cero hasta $\bar{M} = 1{,}75$: el salto posterior tendría que ser casi el **doble** del peor previo.
- Con suavidad, hasta $M = 0{,}02$ (2 puntos por año de cambio en la pendiente).

Medicaid: intervalos robustos



Efecto en 2014; intervalos de 95 % con `HonestDiD`.

- Mayor salto previo: 0,86 puntos.
- Excluye el cero hasta $\bar{M} = 1{,}75$: el salto posterior tendría que ser casi el **doble** del peor previo.
- Con suavidad, hasta $M = 0{,}02$ (2 puntos por año de cambio en la pendiente).

Se discute el **tamaño** de la violación, no el valor p.

3

Tendencias paralelas condicionales

Cuando el control no se parece al tratado

El NSW de la clase 4, **en cambios** (1975 y 1978): 185 tratados contra 15.992 hombres de la CPS. La vara: el DiD del experimento.

	Edad	Educ.	Negros	Casados	Sin ingresos en 1974
Tratados	25,8	10,3	84 %	19 %	71 %
CPS	33,2	12,0	7 %	71 %	12 %

Cuando el control no se parece al tratado

El NSW de la clase 4, **en cambios** (1975 y 1978): 185 tratados contra 15.992 hombres de la CPS. La vara: el DiD del experimento.

	Edad	Educ.	Negros	Casados	Sin ingresos en 1974
Tratados	25,8	10,3	84 %	19 %	71 %
CPS	33,2	12,0	7 %	71 %	12 %

DiD: US$3.621; experimento: US$1.529. Los jóvenes y los que vienen sin trabajo **crecen más** con o sin programa.

Supuesto — Tendencias paralelas condicionales

$E[\Delta Y_i(0) \mid X_i, D_i = 1] = E[\Delta Y_i(0) \mid X_i, D_i = 0]$, y *overlap*: $P(D_i = 1 \mid X_i) < 1$.

¿Agregar X a la regresión de efectos fijos?

Lo primero que se hace: $Y_{it} = \alpha_i + \lambda_t + \tau D_i \mathbf{1}\{t = 1\} + X_i'\beta + \varepsilon_{it}$.

¿Agregar X a la regresión de efectos fijos?

Lo primero que se hace: $Y_{it} = \alpha_i + \lambda_t + \tau D_i \mathbf{1}\{t = 1\} + X_i'\beta + \varepsilon_{it}$.

- Las X_i son **fijas en el tiempo** (edad al entrar, educación, ingreso de 1974). El *within* las borra igual que borra α_i (clase 5): la regresión las descarta y da US$3.621, lo mismo que sin X (pizarra 3).
- Para que X haga algo tiene que afectar la **tendencia**: $X_i \times$ post. Con dos períodos es MCO de ΔY_i en D_i y X_i.

¿Agregar X a la regresión de efectos fijos?

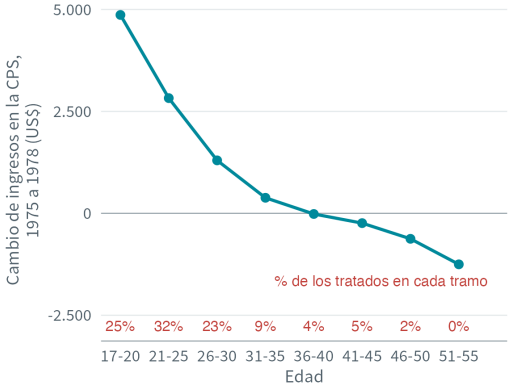
Lo primero que se hace: $Y_{it} = \alpha_i + \lambda_t + \tau D_i \mathbf{1}\{t = 1\} + X_i'\beta + \varepsilon_{it}$.

- Las X_i son **fijas en el tiempo** (edad al entrar, educación, ingreso de 1974). El *within* las borra igual que borra α_i (clase 5): la regresión las descarta y da US$3.621, lo mismo que sin X (pizarra 3).
- Para que X haga algo tiene que afectar la **tendencia**: $X_i \times$ post. Con dos períodos es MCO de ΔY_i en D_i y X_i.

Qué puede fallar

Esa regresión supone que $E[\Delta Y(0) \mid X]$ es **lineal** en X y, si el efecto varía con X, no estima el ATT sino un promedio con los ponderadores de varianza de la clase 4: pesa más donde tratados y controles están balanceados, no donde están los tratados.

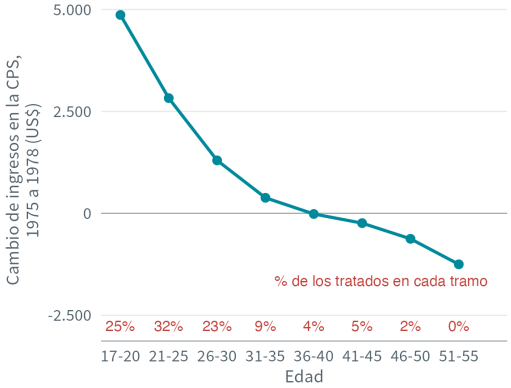
Regresión del resultado (OR-DID)



La tendencia contrafactual de un tratado es la de los controles **con su mismo** X, $\mu_0(X_i)$:

1. MCO de ΔY en X en la CPS: $\hat{\mu}_0$.
2. Predecir $\hat{\mu}_0(X_i)$ para cada tratado.
3. $\widehat{\text{ATT}}$ = promedio en los tratados de $\Delta Y_i - \hat{\mu}_0(X_i)$.

Regresión del resultado (OR-DID)

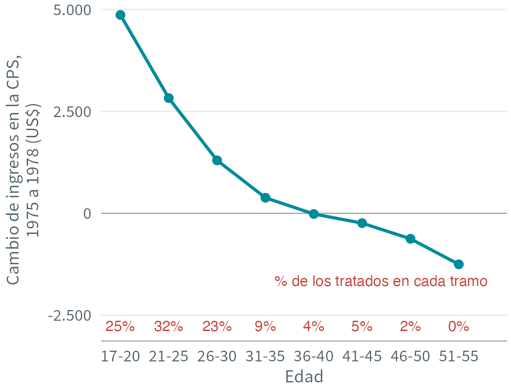


La tendencia contrafactual de un tratado es la de los controles **con su mismo** X, $\mu_0(X_i)$:

1. MCO de ΔY en X en la CPS: $\hat{\mu}_0$.
2. Predecir $\hat{\mu}_0(X_i)$ para cada tratado.
3. $\widehat{\text{ATT}}$ = promedio en los tratados de $\Delta Y_i - \hat{\mu}_0(X_i)$.

Tratados: +US$4.817. CPS: +US$1.196; **con el** X **de los tratados**, +US$3.222. ATT = US$1.595.

Regresión del resultado (OR-DID)



La tendencia contrafactual de un tratado es la de los controles **con su mismo** X, $\mu_0(X_i)$:

1. MCO de ΔY en X en la CPS: $\hat{\mu}_0$.
2. Predecir $\hat{\mu}_0(X_i)$ para cada tratado.
3. $\widehat{\text{ATT}}$ = promedio en los tratados de $\Delta Y_i - \hat{\mu}_0(X_i)$.

Tratados: +US$4.817. CPS: +US$1.196; **con el X de los tratados**, +US$3.222. ATT = US$1.595. Se ajusta donde están los controles y se usa donde están los tratados: si la forma funcional falla allí, el error pasa entero al ATT.

Ponderar (IPW-DID, Abadie 2005)

No modelar ΔY: **repesar los controles** para que se parezcan a los tratados en X.

Celda	Trat.	Contr.	Peso
Joven, sin empleo	9	1	9
Adulto, con empleo	1	99	1/99

Repesados: “9 jóvenes y 1 adulto”, como los tratados. Peso = **razón de chances** $e(x)/(1-e(x))$.

Con muchas X, $\hat{e}(X)$ sale de un logit:

$$\widehat{\mathrm{ATT}} = \overline{\Delta Y}_{D=1} - \sum_{i:\, D_i=0} w_i \, \Delta Y_i,$$

$$w_i \propto \hat{e}(X_i)/(1-\hat{e}(X_i)),\ \sum w_i = 1.$$

Ponderar (IPW-DID, Abadie 2005)

No modelar ΔY: **repesar los controles** para que se parezcan a los tratados en X.

Celda	Trat.	Contr.	Peso
Joven, sin empleo	9	1	9
Adulto, con empleo	1	99	1/99

Repesados: “9 jóvenes y 1 adulto”, como los tratados. Peso = **razón de chances** $e(x)/(1-e(x))$.

Con muchas X, $\hat{e}(X)$ sale de un logit:

$$\widehat{\text{ATT}} = \overline{\Delta Y}_{D=1} - \sum_{i:\, D_i=0} w_i \, \Delta Y_i,$$

$$w_i \propto \hat{e}(X_i)/(1-\hat{e}(X_i)),\ \sum w_i = 1.$$

- NSW: la CPS repesada crece US$2.851 (sin pesos, US$1.196): ATT = US$1.967.
- El costo es el *overlap*: 70 de 15.992 controles llevan la mitad del peso (tamaño efectivo 153).

Doblemente robusto: la intuición

Partir de OR y **corregir su error** con los pesos de IPW:

$$\widehat{\text{ATT}}_{\text{DR}} = \underbrace{\overline{\left(\Delta Y - \hat{\mu}_0(X)\right)_{D=1}}}_{\text{OR}} - \underbrace{\sum_{i:\, D_i=0} w_i \left(\Delta Y_i - \hat{\mu}_0(X_i)\right)}_{\text{error de OR en controles parecidos a los tratados}}$$

Doblemente robusto: la intuición

Partir de OR y **corregir su error** con los pesos de IPW:

$$\widehat{\text{ATT}}_{\text{DR}} = \underbrace{\overline{\left(\Delta Y - \hat{\mu}_0(X)\right)}_{D=1}}_{\text{OR}} - \underbrace{\sum_{i:\, D_i=0} w_i \left(\Delta Y_i - \hat{\mu}_0(X_i)\right)}_{\text{error de OR en controles parecidos a los tratados}}$$

- **Si μ_0 está bien:** los residuos tienen media cero en cada X; con cualquier peso, la corrección es ≈ 0. DR = OR.
- **Si e está bien:** los controles repesados se parecen a los tratados; su residuo medio es el error de OR en los tratados, y se resta (pizarra 4).

Doblemente robusto: la intuición

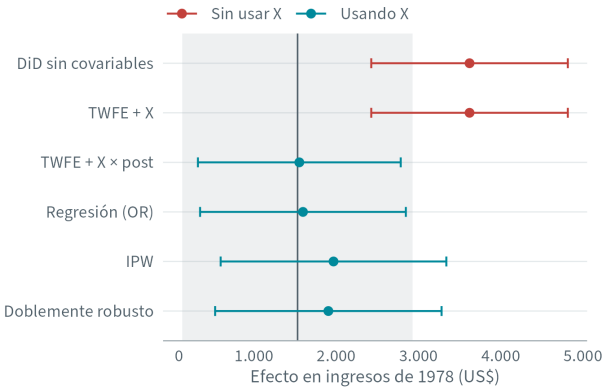
Partir de OR y **corregir su error** con los pesos de IPW:

$$\widehat{\text{ATT}}_{\text{DR}} = \underbrace{\overline{\left(\Delta Y - \hat{\mu}_0(X)\right)}_{D=1}}_{\text{OR}} - \underbrace{\sum_{i:\, D_i=0} w_i \left(\Delta Y_i - \hat{\mu}_0(X_i)\right)}_{\text{error de OR en controles parecidos a los tratados}}$$

- **Si μ_0 está bien:** los residuos tienen media cero en cada X; con cualquier peso, la corrección es ≈ 0. DR = OR.
- **Si e está bien:** los controles repesados se parecen a los tratados; su residuo medio es el error de OR en los tratados, y se resta (pizarra 4).

NSW: en los controles parecidos a los tratados, OR **sobrepredice** el crecimiento en US$309. DR = 1.595 + 309 = US$1.904. Dos oportunidades de acertar con el **modelo**, no con el *overlap*.

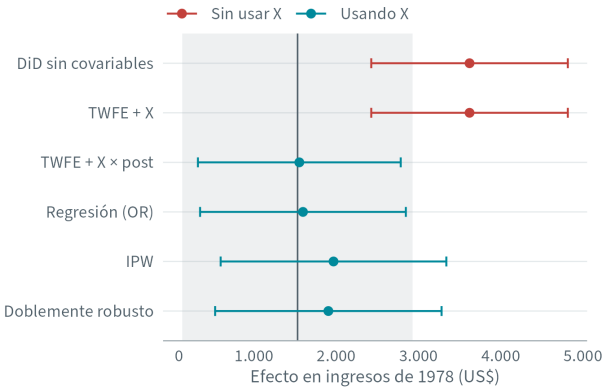
NSW: qué hace cada estimador



Banda gris: el experimento, US$1.529 (e.e. 715). Submuestra de Dehejia y Wahba (1999).

- Sin usar X: US$3.621, más del doble.
- Usando X: entre US$1.551 y US$1.967, todos cerca de la vara.
- Aquí la regresión lineal funciona; no hay garantía de que funcione. DR no exige acertar con ambos modelos.

NSW: qué hace cada estimador



Banda gris: el experimento, US$1.529 (e.e. 715). Submuestra de Dehejia y Wahba (1999).

- Sin usar X: US$3.621, más del doble.
- Usando X: entre US$1.551 y US$1.967, todos cerca de la vara.
- Aquí la regresión lineal funciona; no hay garantía de que funcione. DR no exige acertar con ambos modelos.

Los errores estándar son grandes (~US$703): 185 tratados, y *overlap* escaso.

Cierre

- El estudio de eventos es una colección de 2×2 contra el año previo. Agrupar al nivel de la asignación; cuentan los tratados.
- Las pre-tendencias tienen potencia limitada y filtrar por ellas sesga. Mejor: reportar cuánta violación, relativa a la previa, borraría el efecto (`HonestDiD`).
- Si las tendencias son paralelas solo condicionando en X fijas, la regresión de efectos fijos no puede usarlas. Regresión, ponderación o doblemente robusto (`DRDID`), y mirar el *overlap*.

Lecturas: Roth, Sant'Anna, Bilinski y Poe (2023, *J. Econometrics*), secs. 3–4; Roth (2022, *AER: Insights*); Rambachan y Roth (2023, *ReStud*); Sant'Anna y Zhao (2020, *J. Econometrics*).

El miércoles 28: adopción escalonada. Qué hace la regresión de efectos fijos cuando cada grupo se trata en una fecha distinta (Goodman-Bacon).